

2025년 2학기 통계계산특론

실전편

투자의 정석

주가 수익률 예측 및 투자 전략 수립

목차

1. 프로젝트 소개

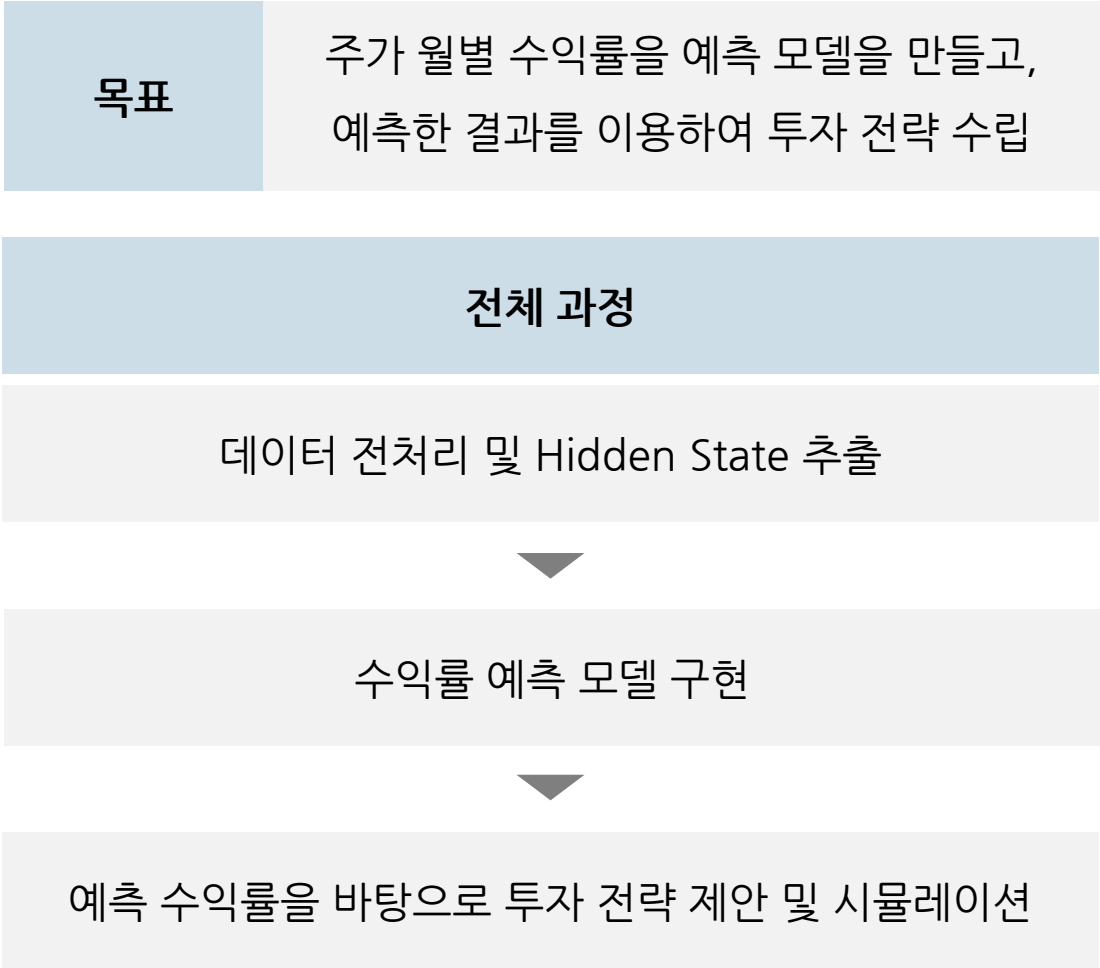
2. 데이터 가공

3. 모델링

4. 투자 전략 시뮬레이션

5. 결론 및 제언

프로젝트 소개



[데이터셋 설명]

	Macroeconomic	Firm Specific
출처	FRED-MD 제공 데이터 (current.csv 다운 후 사용)	CRSP 제공 데이터 (제공 데이터 그대로 사용)
컬럼	127개	60개

[사용한 모델]

	Macroeconomic	Firm Specific
HS 추출	CNN-BiLSTM Random Projection	
	Window 적용 O	Window 적용 X
예측 모델	CatBoost, XGBoost	

데이터 가공

데이터 전처리 : Macroeconomic Data

Macroeconomic Data

결측치

컬럼명	결측치 개수
CP3Mx	1
COMPAPFFx	1

	sasdate	CP3Mx	COMPAPFFx
292	2020-04-01	NaN	NaN



[Note] COMPAPFFx = CP3Mx-FEDFUNDS

- 1. CP3Mx : Linear interpolation
- 2. COMPAPFFx : 보간한 CP3Mx를 이용하여 계산

Lag 적용

컬럼명	Lag 적용 값
S&P PE ratio	6
UMCENTx	12
Others	1

※ The Michigan Survey of Consumer Sentiment



데이터 전처리 : Firm Specific Data

Firm Specific Data

데이터
필터링

각 연도별 Unique 회사(Ticker) 수 요약

평균	4304.1481
최소	1694
최대	6687

시가 총액을 기준으로 매년 Top N개의 기업
데이터만 추출

데이터 크기 비교

원본	1,217,579
Top 1000	288,426
Top 1500	430,583

모델링 시간을 고려하여 Top 1000 데이터 선택

결측치
처리

각 컬럼별 결측치 개수


hire	92
cinvest	510
chpm	387
depr	491
pctacc	24
pm	2230
rd_sale	1286
sgr	591

1. Inf, -Inf 값을 결측치로 처리
2. Forward Fill : 과거 값으로 채우기
3. 남은 결측치는 0으로 처리

변수 제거

sasdate 컬럼과 Year 컬럼이 함께 존재.
Year 컬럼이 sasdate에서 추출된 값 → 제거

Data Split



Hidden State 추출

구분	Macroeconomic Data	Firm Specific Data
모델	CNN으로 1차 Hidden State 추출 후, Bidirectional LSTM으로 2차 Hidden State 추출(Random Projection)	
알고리즘	Window 6개월 적용(과거 6개월의 패턴을 봄)	Window 적용 X(현재 시점의 기업 재무 상태만 봄)

Hidden State 개수 조합	CNN	Bi-LSTM	총 4개의 Hidden State 조합에 대하여 모델링		Hidden State 추출에서 제외된 컬럼 (Firm Specific Data)	컬럼명	설명
	5	5				ticker	회사 이름
	10	5				gvkey	Compustat의 고유 식별번호
		10	permno	CRSP 고유 식별번호			
	20	5					
		10					
		20	50	5		Macro	Firm
	10	50-20		20-20			
	20	50-20		50-20			
	50	20-10		20-20			
	50	50-10	20-20				
						ret	수익률(Target)

PART 3

모델링

CatBoost 모델 Validation 결과

- Train 데이터 학습한 모델을 이용하여, Validation 데이터에 대하여 예측하고 R-squared 값 계산
- R-square의 평균값이 가장 좋은 Dataset3으로 학습한 모델을 CatBoost 최적 모델로 선정
- Train+Validation 데이터로 최종 학습을 진행한 후, Test 데이터에 대해 예측

No	Hidden States 조합 (CNN-BiLSTM)		Validation 기간 : 3년				
	Macroeconomic	Firm	2015~2017	2016~2018	2017~2019	2018~2020	평균
1	50-20	20-20	0.004297	0.011849	0.013928	0.021952	0.015910
2	50-20	50-20	0.006587	0.016519	0.005407	0.024439	0.013238
3	20-10	20-20	0.003840	0.004367	0.005775	0.075978	0.022490
4	50-10	20-20	0.010053	0.011778	0.002125	-0.001015	0.005735

[각 조합 별 Validation 데이터 R-squared 결과]

XGBoost 모델 Validation 결과

- Train 데이터 학습한 모델을 이용하여, Validation 데이터에 대하여 예측하고 R-squared 값 계산
- R-square의 평균값이 가장 좋은 Dataset3으로 학습한 모델을 XGBoost 최적 모델로 선정
- Train+Validation 데이터로 최종 학습을 진행한 후, Test 데이터에 대해 예측

No	Hidden States 조합 (CNN-BiLSTM)		Validation 기간 : 3년				
	Macroeconomic	Firm	2015~2017	2016~2018	2017~2019	2018~2020	평균
1	50-20	20-20	0.000982	0.005454	0.000613	0.005872	0.003230
2	50-20	50-20	0.000982	0.005839	0.000613	0.006788	0.003556
3	20-10	20-20	0.000136	-0.001559	0.004321	0.030488	0.008347
4	50-10	20-20	-0.000659	-0.012425	0.004771	-0.000641	-0.002239

[각 조합 별 Validation 데이터 R-squared 결과]

CatBoost & XGBoost 최적 모델 비교

Model	Hidden States 조합 (CNN-BiLSTM)		Validation 기간(3년)				
	Macro-economic	Firm	2015~2017	2016~2018	2017~2019	2018~2020	평균
CatBoost	20-10	20-20	0.003840	0.003163	0.005775	0.075978	0.022189
XGBoost	20-10	20-20	0.000136	-0.001559	0.004321	0.030488	0.008347

투자 전략 시뮬레이션

투자 전략 요약

Benchmark (방치형)

“좋은 것을 사고 잊자.”

주요 전략

2018년 1월 Top N 매수

Top N 기준

수익률

시가 총액

수익률 집중 (불나방형)

“중요한 건 수익률이다.”

주요 전략

2018년 1월에 Top N 매수.

2018년 2월부터는
매달 수익률을 기준으로
Bottom N개 매도,
Top N개를 새로 매수

매도 임계값 O/X

가중치 기준

균등

시가 총액 비례

수익률 비례

Beta 계수 활용 (안정형)

“시장 변동성을 반영하자.”

주요 전략

2018년 1월에 Top N 매수.

2018년 2월부터는
매달 수익률, Beta 계수를 기준으로
Bottom N개 매도,
Top N개를 새로 매수

매도 임계값 O/X

가중치 기준

균등

시가 총액 비례

Smart score 비례

투자 전략 요약

$$\text{베타 계수} = \frac{\text{개별 종목의 수익률 변동폭}}{\text{시장의 주가 수익률 변동폭}}$$

Benchmark (방치형)

“좋은 것을 사고 잊자.”

주요 전략

2018년 1월 Top N 매수

Top N 기준

수익률

시가 총액

수익률 집중 (불나방형)

“중요한 건 수익률이다.”

주요 전략

2018년 1월에 Top N 매수.

2018년 2월부터는
매달 수익률을 기준으로
Bottom N개 매도,
Top N개를 새로 매수

매도 임계값 O/X

가중치 기준

균등

시가 총액 비례

수익률 비례

Beta 계수 활용 (안정형)

“시장 변동성을 반영하자.”

주요 전략

2018년 1월에 Top N 매수.

2018년 2월부터는
매달 수익률, **Beta 계수**를 기준으로
Bottom N개 매도,
Top N개를 새로 매수

매도 임계값 O/X


가중치 기준

균등

시가 총액 비례




Smart score 비례

각 투자 전략별 최적 포트폴리오 - 수익률 집중




전략	매도 임계값 X		
	균등	시가 총액 비례	수익률 비례
수익률	430.53%	430.53%	430.53%
초기매수	100	100	100
매도(Sell)	5	5	5
매수(Buy)	1	1	1

각 투자 전략별 최적 포트폴리오 - 수익률 집중



전략	매도 임계값 0		
	균등	시가 총액 비례	수익률 비례
수익률	171.58%	221.35%	221.35%
초기매수	50	50	50
매도(Sell)	5	20	20
매수(Buy)	5	1	1

Benchmark VS 수익률 집중




전략	가중치	최종 수익률
매도 임계값 X	균등	430.53%
	시가 총액 비례	430.53%
	수익률 비례	430.53%
매도 임계값 O	균등	171.58%
	시가 총액 비례	221.35%
	수익률 비례	221.35%
단순	수익률	229.21%
	시가 총액	99.48%

최적 포트폴리오 분석 - 수익률 집중




Ticker	업종
AMC	영화 상영 사업
IMMU	바이오 제약 회사
NVAX	백신 개발 회사
TSLA	전기자동차 회사
MRTX	암 치료제를 개발하는 회사
ROKU	스트리밍 기술 기업
EQT	미국 에너지 회사
MDB	미국의 소프트웨어 회사(DB 엔진)
TNDM	미국의 의료 기기 제조업체
DXC	정보기술 서비스 및 컨설팅 회사

각 투자 전략별 최적 포트폴리오 - Beta 계수 활용




전략	매도 임계값 X		
	균등	시가 총액 비례	beta 비례
수익률	134.6%	112.7%	144.5%
초기매수	100	100	100
매도(Sell)	5	5	5
매수(Buy)	5	5	5

각 투자 전략별 최적 포트폴리오 - Beta 계수 활용




전략	매도 임계값 0		
	균등	시가 총액 비례	beta 비례
수익률	197.6%	120.5%	255.8%
초기매수	50	50	50
매도(Sell)	5	5	5
매수(Buy)	매도한 만큼	매도한 만큼	매도한 만큼

Benchmark VS Beta 계수 활용



전략	가중치	최종 수익률
매도 임계값 X	균등	134.6%
	시가 총액 비례	112.7%
	beta 비례	144.5%
매도 임계값 O	균등	197.6%
	시가 총액 비례	120.5%
	beta 비례	255.8%
단순	Low vol	81.6%
	시가 총액	86.5%

최적 포트폴리오 분석 - Beta 계수 활용



Ticker	업종
OKTA	ID 및 액세스 관리 회사
TTD	클라우드 기반 광고 구매 플랫폼
HUBS	영업 및 고객 서비스용 소프트웨어 제품 개발
FANG	석유 & 가스 에너지 개발 및 생산회사
ETSY	웹2.0을 기반으로 한 전자상거래 사이트
SNAP	카메라 및 소셜 미디어
MSFT	소프트웨어 및 클라우드 기업
ALGN	치과 의료 기기 개발 및 판매 회사
KLAC	반도체 장비 및 검사 장비 제조 회사
RNG	클라우드 기반 통신 및 협업 제품과 서비스를 제공하는 회사

결론 및 제언

Test 데이터 R-squared 결과

CatBoost	No	Hidden States 조합 (CNN-BiLSTM)		Test 데이터 : 1년				
		Macro-economic	Firm	2018	2019	2020	2021	평균
	1	50-20	20-20	-0.030180	-0.091090	-0.158455	0.011832	-0.066973
	2	50-20	50-20	-0.111979	-0.050148	-0.064048	-0.009251	-0.058856
	3	20-10	20-20	-0.060698	-0.056234	-0.001451	0.011707	-0.026669
	4	50-10	20-20	-0.039500	-0.317546	-0.420242	-0.016380	-0.198417

XGBoost	No	Hidden States 조합 (CNN-BiLSTM)		Test 데이터 : 1년				
		Macro-economic	Firm	2018	2019	2020	2021	평균
	1	50-20	20-20	-0.130660	-0.708061	-0.115522	-0.158655	-0.278225
	2	50-20	50-20	-0.144303	-0.599746	-0.128621	-0.132837	-0.251377
	3	20-10	20-20	-0.148851	-0.258951	-0.485788	-0.045814	-0.234851
	4	50-10	20-20	-0.238505	-0.847180	-0.160146	-0.099249	-0.33627

프로젝트 결과 요약 및 제언

Q. 단순한 '장기 보유 전략'을 앞설 수 있을까?

시장 국면(6개월 추세)에 따라 비중을 조절하는 동적 자산 배분이 수익률 방어와 극대화에 효과적임.

Q. 왜 결과가 좋게 나왔을까?


- Data Leakage 발생 : 과거 시점의 결측치가 사후적으로 채워진 최신 데이터를 사용 → 예측 정확도가 과대평가됨.

한계점 및 제언

- 딥러닝 모델 미적용 및 월간 데이터의 한계 → 딥러닝 도입 및 일별 데이터 활용
- 시계열 특성을 고려하지 못한 데이터 분할 → 미래 참조 편향 방지를 위한 전처리 탐색
- 환율, 금리 등의 거시경제 지표 추가
- 국내 시장 (KOSPI / KOSDAQ) 적용
- 2022~2025년 최신 데이터를 활용한 실전 예측 성능 검증

추가 분석

Macroeconomic Data 재구성



데이터 전처리						
각 데이터 공통 컬럼	연도		컬럼개수	124개의 공통 컬럼 존재	결측치	각 데이터 마지막 1~3행(10~12월)에 다수의 결측치 존재
	2018		128			1. CP3Mx와 다른 컬럼들 : Forward Fill 2. COMPAPFFx : CP3Mx로 계산
	2019		128			
	2020		128			
	2021		127			
				Lag 1 적용	경제 지표 발표까지 1~2달의 지연 존재	

CatBoost 모델링 결과

Validation	No	Hidden States 조합 (CNN-BiLSTM)		Validation 데이터 : 3년				
		Macro-economic	Firm	2015~2017	2016~2018	2017~2019	2018~2020	평균
	1	50-20	20-20	0.010654	0.013304	0.014847	0.006575	0.011345
	2	50-20	50-20	0.009436	0.021287	0.014830	0.005075	0.012657
	3	20-10	20-20	0.004234	0.003112	0.002979	0.006835	0.004309
	4	50-10	20-20	0.006540	0.001900	0.004028	0.037178	0.012412

Test	No	Hidden States 조합 (CNN-BiLSTM)		Test 데이터 : 1년				
		Macro-economic	Firm	2018	2019	2020	2021	평균
	1	50-20	20-20	-0.094493	-0.059531	0.000113	-0.022639	-0.04413750
	2	50-20	50-20	-0.040131	-0.034481	-0.110847	-0.014536	-0.04999875
	3	20-10	20-20	-0.300071	-0.307109	-0.052171	-0.037467	-0.17420450
	4	50-10	20-20	-0.293657	-0.050022	-0.051810	-0.005884	-0.10034325

감사합니다.